

Sprawozdanie Projektowe: System Integracji Danych Rynku Pracy i Edukacji

Nazwa zespołu: Azure Enjoyers

Skład zespołu: Jan Taran, Piotr Wysocki

14 czerwca 2026

Spis treści

1	Cel projektu i planowane korzyści	3
1.1	1.1 Koncepcja (Business Case) z perspektywy odbiorcy	3
1.2	1.2 Cel projektu	3
1.3	1.3 Planowane korzyści dla użytkownika	3
2	Architektura rozwiązania	3
2.1	Diagram architektury	3
2.2	Opis komponentów i warstw systemu	3
3	Opis zbiorów danych	5
3.1	Zbiór danych o kosztach edukacji (dane statyczne)	5
3.2	Zbiór danych o ofertach pracy (dane dynamiczne)	6
3.3	Analiza jakości danych po wgraniu do hurtowni:	7
4	Proces ELT (Extract, Load, Transform)	7
4.1	Potok 1: Przetwarzanie kosztów edukacji (pipeline1)	7
4.2	Potok 2: Ingestycja z API Adzuna (PL_Ingest_Adzuna)	8
5	Model fizyczny hurtowni danych	9
5.1	Diagram encji-relacji (ERD)	9
6	Kluczowe miary, atrybuty i hierarchie	9
6.1	Kluczowe miary (Tabele Faktów)	9
6.2	Kluczowe atrybuty i hierarchie (Tabele Wymiarów)	10
7	Warstwa raportowa i model semantyczny	10
7.1	Tryb dostępu do danych i odświeżanie	10
7.2	Model semantyczny i relacje w narzędziu BI	11
7.3	Transformacje i miary kalkulowane (DAX)	11
8	Realizacja przykładowych raportów dla użytkownika	11
8.1	Globalny Dashboard Career-ROI (Perspektywa Makro)	11
8.2	Projekt Symulatora Kosztów (Perspektywa Mikro)	12
9	Testy funkcjonalne systemu (End-to-End)	13
9.1	Test 1: Inicjalizacja systemu i warstwa ELT (Pobieranie danych)	14
9.2	Test 2: Poprawność transformacji i spójność relacyjna (Hurtownia Danych)	15
9.3	Test 3: Scenariusz kolejnej iteracji (Zarządzanie statusem is_active)	16
9.4	Testowanie potoków w Azure Data Factory	16
9.5	Walidacja End-to-End na warstwie prezentacyjnej (Raporty BI)	17
10	Podział prac	21
11	Podsumowanie i ocena biznesowa rozwiązania	21
11.1	Realizacja strategicznego celu biznesowego	21
11.2	Ocena jakości rozwiązania z perspektywy biznesu	21
11.3	Skalowalność i perspektywy rozwoju	21

1 Cel projektu i planowane korzyści

1.1 1.1 Koncepcja (Business Case) z perspektywy odbiorcy

Projekt realizowany jest pod szyldem firmy doradztwa edukacyjno-zawodowego „Global Career Pathfinders”, której misją jest wsparcie studentów oraz młodych profesjonalistów w podejmowaniu kluczowych decyzji o relokacji i wyborze ścieżki kształcenia.

Współczesny kandydat na studia, w szczególności w obszarze Data Science, mierzy się z problemem uciążliwego rozproszenia danych. Obecnie musi on osobno analizować rankingi uczelni, weryfikować koszty życia w różnych portalach oraz samodzielnie szukać informacji o prognozowanych zarobkach. Nasze rozwiązanie rozwiązuje ten problem – konsoliduje wszystkie te dane w jednym miejscu, pozwalając użytkownikowi na szybką i miarodajną ocenę realnej wartości dyplomu w danym kraju.

1.2 1.2 Cel projektu

Głównym celem rozwiązania jest dostarczenie odbiorcy autorskiego wskaźnika **Career-ROI (Return on Investment)**. System ma w przystępny sposób odpowiedzieć na najważniejsze pytanie użytkownika: *W którym kraju moja inwestycja w edukację IT zwróci się najszybciej, biorąc pod uwagę lokalne koszty życia i aktualną podaż ofert pracy?*

1.3 1.3 Planowane korzyści dla użytkownika

Z perspektywy odbiorcy rozwiązania, wdrożenie systemu zapewni następujące wartości:

- **Oszczędność czasu:** Eliminacja konieczności żmudnego przeszukiwania wielu stron internetowych i ręcznego łączenia ze sobą informacji z różnych źródeł.
- **Wielowymiarowa analiza decyzyjna:** Kompleksowe spojrzenie na wybór ścieżki kariery, uwzględniające zarówno aspekt edukacyjny, jak i życiowy.
- **Świadomość finansowa:** Możliwość precyzyjnego oszacowania ryzyka finansowego i początkowych kosztów przed podjęciem ostatecznej decyzji o wyjeździe na uczelnię.
- **Weryfikacja rynku pracy:** Przejrzysty wgląd w realne, aktualne zapotrzebowanie na specjalistów w docelowym kraju.


2 Architektura rozwiązania

2.1 Diagram architektury

2.2 Opis komponentów i warstw systemu

Na podstawie dostarczonego diagramu oraz analizy plików źródłowych, system reprezentuje klasyczną architekturę **ELT (Extract, Load, Transform)** zbudowaną w oparciu o ekosystem chmury Microsoft Azure. Cała infrastruktura została logicznie zgrupowana w ramach jednej **Grupy Zasobów (Resource Group)**, w której powołano następujące usługi: serwer bazy danych (Database Server), Azure SQL Database, Azure Data Factory oraz konto magazynu danych (Data Storage).

Poniżej znajduje się krótki opis poszczególnych warstw rozwiązania:



Rysunek 1: Diagram

1. Źródła danych (Data Sources)

System integruje dane z dwóch zróżnicowanych źródeł:

- **Adzuna API:** Dynamiczne źródło dostarczające aktualne oferty pracy. Dane są pobierane w formacie **JSON** za pomocą żądań REST/HTTP.
- **Kaggle:** Statyczny plik **CSV** zawierający dane o globalnych kosztach edukacji.

2. Warstwa Ekstrakcji i Data Lake (Warstwa ELT)

Głównym orkiestratorem przepływu danych jest **Azure Data Factory (ADF)**. W ramach warstwy ekstrakcji:

- ADF odpowiada za pobranie surowych danych ze źródeł.
- Trafiają one do usługi **Data Storage** pełniącej rolę Data Lake (warstwa Landing/Raw). Utworzono tam dedykowany **kontener**, w którym trzymany jest wspomniany plik CSV oraz gdzie składowane są na bieżąco pobierane z API pliki JSON.

3. Hurtownia Danych i Transformacje (Data Warehouse)

Po zrzućeniu danych do kontenera, ADF ładuje je do tabel tymczasowych (Staging) w **Azure SQL Database** (hostowanej na powołanym **Database Server**). Przykładowe tabele tymczasowe to `stg_job_postings` oraz `stg_education_costs`.

- Ładowanie danych obsługują pipeline w Azure Data factory
- To baza SQL pełni właściwą rolę silnika transformacji, parsując struktury JSON i modelując dane docelowe za pomocą procedur składowanych.
- Dane są układane w **Model Galaktyki (Star Schema)**, zasilając tabele faktów (`fact_job_postings`, `fact_education_cost`) oraz powiązane z nimi tabele wymiarów (np. `DimTerritory`, `DimDate`), z których część wykorzystuje mechanizm historyzacji **SCD Type 2**.

4. Warstwa BI (Business Intelligence)

Gotowe, ustrukturyzowane modele analityczne z Azure SQL Database są podpinane do narzędzia **Power BI**. Służy ono do ostatecznej agregacji i wizualizacji danych w formie interaktywnych dashboardów dla użytkowników końcowych.

3 Opis zbiorów danych

3.1 Zbiór danych o kosztach edukacji (dane statyczne)

Pierwszym z wykorzystywanych w projekcie zbiorów danych jest plik w formacie CSV, zawierający szczegółowe informacje o kosztach edukacji i życia dla studentów. Stanowi on statyczną część zasilającą hurtownię danych, przechowywaną w usłudze Azure Blob Storage.

Struktura zbioru obejmuje następujące kolumny:

- **Country** – kraj, w którym znajduje się uczelnia.
- **City** – miasto lokalizacji uczelni (stanowiące główny klucz integracji ze zbiorem ofert pracy).
- **University** – nazwa placówki edukacyjnej.
- **Program** – nazwa kierunku studiów (np. Computer Science, Data Science).
- **Level** – stopień edukacji (np. Master, Bachelor, PhD).
- **Duration_Years** – czas trwania programu studiów wyrażony w latach.
- **Tuition_USD** – roczne czesne za studia przeliczone na dolary amerykańskie.
- **Living_Cost_Index** – wskaźnik kosztów życia w danym mieście.
- **Rent_USD** – szacunkowy miesięczny koszt wynajmu zakwaterowania w dolarach amerykańskich.
- **Visa_Fee_USD** – jednorazowy koszt wyrobienia wizy studenckiej.
- **Insurance_USD** – roczny koszt ubezpieczenia zdrowotnego.
- **Exchange_Rate** – kurs wymiany lokalnej waluty na USD, kluczowy z perspektywy procesu transformacji i ujednolicania walut.

Istotną zaletą wybranego zestawu danych jest jego nienaganna jakość – zbiór jest kompletny i nie posiada żadnych braków (zero wartości null), co znacząco upraszcza fazę czyszczenia i eliminuje konieczność stosowania technik imputacji.

Dostęp i częstotliwość odświeżania: Z racji swojego charakteru, dane o kosztach edukacji i życia cechują się relatywnie niską dynamiką zmian. Zbiór źródłowy na platformie Kaggle podlega corocznej aktualizacji (cykl roczny). Zgodnie z tym cyklem, dane w hurtowni będą odświeżane z częstotliwością roczną, co jest interwałem w pełni wystarczającym do zachowania wysokiej wiarygodności docelowego wskaźnika Career-ROI.

3.2 Zbiór danych o ofertach pracy (dane dynamiczne)

Drugim kluczowym komponentem systemu jest dynamiczny zbiór danych pozyskiwany za pośrednictwem interfejsu programistycznego **Adzuna REST API**. Dane te dostarczają bieżących informacji o zapotrzebowaniu na rynku pracy w sektorach Data Science, AI oraz ML. Proces ekstrakcji jest w pełni zautomatyzowany przy użyciu usługi Azure Data Factory, która pobiera surowe obiekty w formacie JSON i przekształca je w strukturę relacyjną.

Struktura danych po procesie mapowania obejmuje następujące kolumny:

- **job_id** - unikalny identyfikator oferty pracy nadawany przez system źródłowy.
- **country** - kod kraju.
- **city** - nazwa miasta, zdefiniowana na podstawie listy miast z pliku kosztów edukacji, stanowiąca precyzyjny punkt styku obu zbiorów (JOIN key).
- **title** - nazwa stanowiska pracy, podlegająca filtracji pod kątem słów kluczowych (np. Analyst, Engineer).
- **company_name** - nazwa pracodawcy lub agencji rekrutacyjnej.
- **salary_min** - minimalne przewidywane wynagrodzenie.
- **salary_max** - maksymalne przewidywane wynagrodzenie.
- **latitude** - szerokość geograficzna miejsca pracy.
- **longitude** - długość geograficzna miejsca pracy.
- **contract_time** - wymiar czasowy umowy.
- **job_category** - typ pracy.
- **created_at** - data zamieszczenia ogłoszenia.
- **url** - link do oferty pracy.

W przeciwieństwie do zbioru statycznego, dane rekrutacyjne charakteryzują się dużą zmiennością oraz występowaniem braków danych (szczególnie w polach dotyczących widełek płacowych). W fazie transformacji stosowana jest logika filtracji rekordów niekompletnych, aby zapewnić rzetelność wyliczeń średnich zarobków dla danego regionu.

Dostęp i częstotliwość odświeżania:

Dane o ofertach pracy cechują się bardzo wysoką dynamiką. Cykl życia ogłoszenia w branży IT wynosi zazwyczaj od 14 do 30 dni. Aby system dostarczał aktualnych informacji o trendach płacowych, zaplanowano cykl odświeżania danych w interwale tygodniowym. Proces ten jest realizowany automatycznie przez mechanizm *Trigger* w Azure Data Factory, który wyzwała raz w tygodniu potok danych (pipeline) pobierający nowe rekordy i archiwizujący te, które straciły ważność.

3.3 Analiza jakości danych po wgraniu do hurtowni:

Finanse:

1. Brak błędów w danych takich jak wynagrodzenie minimalne większe od maksymalnego.
2. Odniesienie do waluty występuje za każdym razem, co wynika z logiki ELT wysokiej jakości pliku csv, gdzie istnieją wszystkie pola.
3. Procent danych gdzie stawka jest poniżej 10000 USD - prawdopodobnie błąd lub jest miesięczna/godzinowa, a nie roczna - 3.08% danych, w tym potencjalnie godzinowe (< 500\$) - 0.98%.

Wymiar terytorium:

1. Brak współrzędnych geograficznych: 69.45% danych.
2. Dla każdej oferty pracy znajduje się miasto, z którego pochodzi. Wynika to z zastosowanego mechanizmu, że pobieramy oferty pracy tylko dla miast, które są w csv.

Wymiar atrybutów pracy:

1. W 55,13% danych brakuje informacji o wymiarze czasowym pracy.

4 Proces ELT (Extract, Load, Transform)

Architektura przepływu danych w systemie została zaprojektowana zgodnie z paradygmatem ELT, w którym główny ciężar transformacji danych przeniesiony jest na relacyjną bazę docelową (Azure SQL Database). Głównym orkiestratorem procesu jest Azure Data Factory (ADF). W systemie zdefiniowano dwa główne, niezależne potoki (pipelines), z których każdy realizuje pełen przepływ danych (od ekstrakcji ze źródeł, po transformację i załadowanie do docelowego Modelu Galaktyki).

4.1 Potok 1: Przetwarzanie kosztów edukacji (pipeline1)

Ten potok odpowiada za integrację statycznych danych pochodzących z platformy Kaggle (plik CSV).

- **Ekstrakcja i Ładowanie (E-L):** Aktywność Copy_CSV_to_SQL pobiera plik CSV znajdujący się w warstwie Data Lake (Azure Blob Storage) i ładuje go bezpośrednio do tabeli `stg_education_costs` w Azure SQL. Przed zrzutem danych tabela jest każdorazowo czyszczona (skrypt pre-copy TRUNCATE).
- **Transformacja (T):** Data Factory uruchamia w wyznaczonej kolejności procedury składowane (Stored Procedures) bezpośrednio na silniku bazy danych. Najpierw aktualizowane i zasilane są wymiary `DimMajor` (kierunki studiów) oraz `DimCurrency` (waluty), a po ich pomyślnym zakończeniu ładowana jest tabela `fact_education_cost`.



Rysunek 2: Diagram ELT

4.2 Potok 2: Ingestycja z API Adzuna (PL_Ingest_Adzuna)

Drugi potok realizuje złożony scenariusz pobierania dynamicznych ofert pracy z zewnętrznego interfejsu REST.

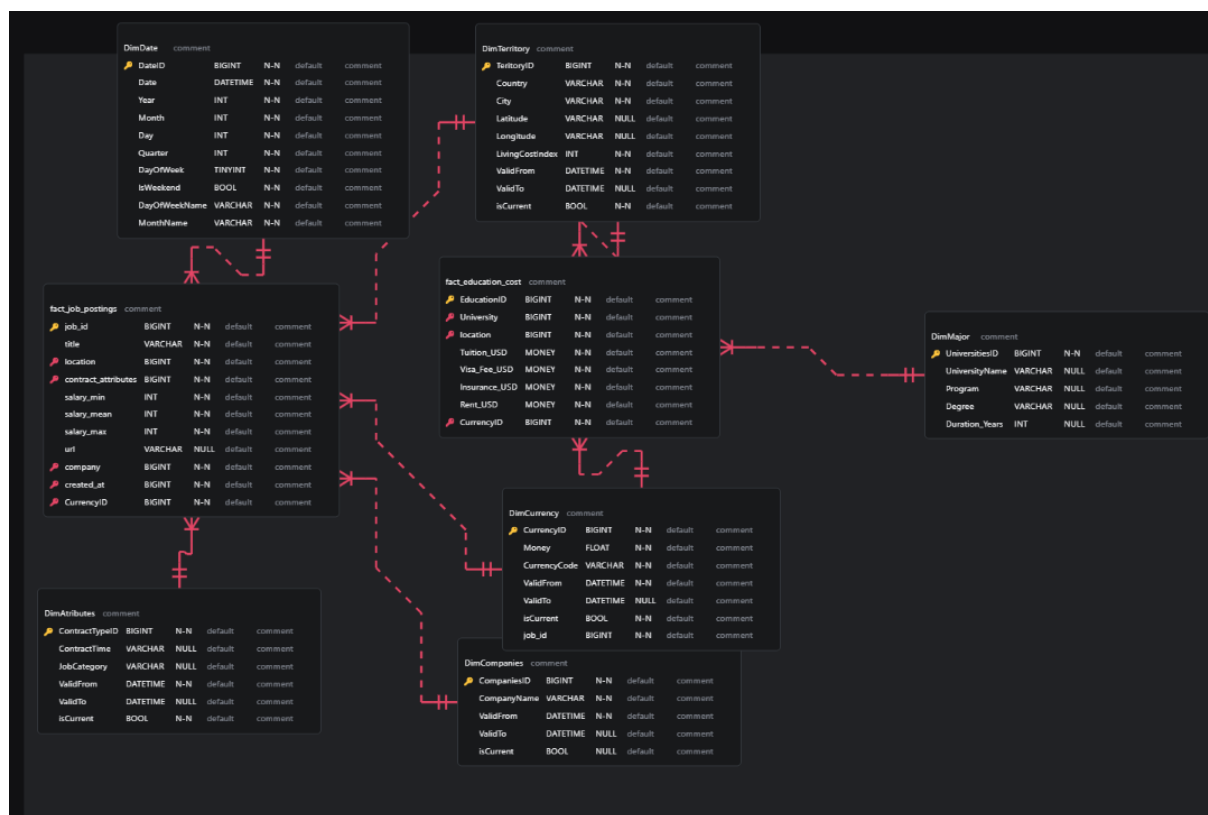
- Inteligentna Ekstrakcja (E):** Proces rozpoczyna się od aktywności Lookup (Get_Cities_And_Countries), która za pomocą zapytania SQL weryfikuje w docelowej bazie danych dla jakich miast system ma zebrać oferty (zależność od lokalizacji w tabeli kosztów edukacji). Następnie, w asynchronicznej pętli (ForEach), potok wysyła zapytania HTTP (GET) do Adzuna API dla każdego miasta, które obsługuje API z osobna, wykorzystując wcześniej przygotowany mapping nazw krajów przechowywany w osobnej tabeli między nazwami z pliku o edukacji a tymi, które obsługuje API. Pobrane surowe dane w formacie JSON są archiwizowane w specjalnie wyznaczonym kontenerze w Data Lake.
- Ładowanie (L):** Aktywność Load_to_STG kopiuje zawartość wszystkich nowo zrzuconych plików JSON ze Storage'u hurtowo do tabeli `stg_job_postings` w bazie SQL. Cały dokument JSON ładuje tekstowo w jednej kolumnie (`RawJsonData`).
- Transformacja (T):** Pierwszym krokiem transformacji jest uruchomienie w Azure SQL procedury `usp_01_Parse_JSON_To_Staging`, która wykorzystuje wbudowane funkcje silnika (OPENJSON) do spłaszczenia i rozpakowania atrybutów z formatu JSON na postać relacyjną. Następnie ADF wywołuje sekwencyjnie procedury uzupełniające wymiary (`DimTerritory`, `DimCompanies`, `DimAttributes`), które dodatkowo wspierają mechanizm wolno zmieniających się wymiarów **SCD Type 2**. W przypadku Territory do wyznaczenia Longitude oraz Latitude, by zachować ziarnistość wyznaczana jest średnia z tych współrzędnych dla całego miasta, a SCD2 jest stosowany tylko przy zmianie LivingCostIndex (zmiana współrzędnych będzie częsta z powodu ich dynamicznego wyliczania, więc nie jest traktowana jako zmiana danych). Zwieńczeniem całego potoku jest załadowanie ostatecznych wyników do tabeli `fact_job_postings`.



Rysunek 3: Diagram ELT

5 Model fizyczny hurtowni danych

5.1 Diagram encji-relacji (ERD)



Rysunek 4: Diagram modelu hurtowni danych

6 Kluczowe miary, atrybuty i hierarchie

6.1 Kluczowe miary (Tabele Faktów)

W zaprojektowanym modelu hurtowni danych wyodrębniono dwie tabele faktów, które gromadzą zjawiska biznesowe i przechowują poddawane analizie miary liczbowe:

- **Fakty ofert pracy (fact_job_postings):** Centralna tabela przechowująca dane z rynku IT. Główne miary to finansowe aspekty zatrudnienia: dolna (**salary_min**) i górna (**salary_max**) granica oferowanych widełek wynagrodzenia oraz wyliczona na ich podstawie średnia (**salary_mean**). Dodatkowo agreguje atrybuty techniczne oferty, takie jak jej identyfikator (**job_id**), nazwa stanowiska (**title**) oraz adres URL (**url**). Oparta jest na zestawie kluczy obcych łączących ją z wymiarami czasu, lokalizacji, atrybutów stanowiska, firmy oraz waluty.
- **Fakty kosztów edukacji (fact_education_cost):** Skupia się na metrykach finansowych związanych ze studiowaniem i życiem w poszczególnych ośrodkach akademickich. Kluczowe miary w tej tabeli to znormalizowane (do USD) koszty rocznego czesnego (**Tuition_USD**), ubezpieczenia (**Insurance_USD**), opłaty wizowe (**Visa_Fee_USD**)

oraz roczny koszt wynajmu mieszkania (*Rent_USD*). Fakty te mapowane są na odpowiednie uczelnie, terytoria oraz waluty.

6.2 Kluczowe atrybuty i hierarchie (Tabele Wymiarów)

Tabele wymiarów nadają kontekst analityczny zgromadzonym faktom, umożliwiając ich grupowanie, filtrowanie i analizę trendów. Część z nich odwzorowuje naturalne hierarchie biznesowe:

- **Wymiar Czasu (DimDate):** Rozbudowana tabela kalendarzowa z klasyczną hierarchią: *Rok (Year)* → *Kwartał (Quarter)* → *Miesiąc (Month)* → *Dzień (Day)*. Atrybuty pomocnicze, jak dzień tygodnia (*DayOfWeekName*) czy flaga weekendu (*IsWeekend*), umożliwiają badanie trendów publikacji w konkretnych dniach.
- **Wymiar Terytorialny (DimTerritory):** Modeluje przestrzeń geograficzną poprzez hierarchię: *Kraj (Country)* → *Miasto (City)*. Zawiera cenne atrybuty przestrzenne (współrzędne *Latitude*, *Longitude*) pozwalające na tworzenie map oraz agreguje wskaźnik kosztów (*LivingCostIndex*).
- **Wymiar Kierunków Edukacji (DimMajor):** Strukturyzuje środowisko akademickie wokół hierarchii: *Uczelnia (UniversityName)* → *Program (Program)* → *Stopień (Degree)*. Przechowuje również kluczowy atrybut czasu trwania nauki (*Duration_Years*).
- **Pozostałe wymiary płaskie i słownikowe:**
 - **DimCompanies:** Baza unikalnych nazw firm i pracodawców (*CompanyName*).
 - **DimAttributes:** Kategoryzuje warunki zatrudnienia (rodzaj umowy / czas pracy w *ContractTime*) oraz dziedzinę (*JobCategory*).
 - **DimCurrency:** Struktura wspierająca spójność finansową, zachowująca kod waluty (*CurrencyCode*) i powiązany z nią bieżący przelicznik (*Money*).

Aby zagwarantować spójność historyczną danych, wszystkie wymiary z wyłączeniem kalendarza (*DimTerritory*, *DimMajor*, *DimCompanies*, *DimAttributes*, *DimCurrency*) zostały zaprojektowane zgodnie ze wzorcem **SCD Type 2** (Slowly Changing Dimensions) i wyposażone w systemowe atrybuty *ValidFrom*, *ValidTo* oraz flagę aktualności *isCurrent*.

7 Warstwa raportowa i model semantyczny

7.1 Tryb dostępu do danych i odświeżanie

W systemie zaimplementowano zautomatyzowany model odświeżania danych z wykorzystaniem usługi Azure Data Factory, która orkiestruje przepływ do docelowej hurtowni (Azure SQL Database). Z kolei na warstwie wizualizacyjnej zastosowano podejście optymalizujące wydajność raportowania.

Biorąc pod uwagę tygodniowy cykl aktualizacji bazy oraz konieczność wykonywania złożonych kalkulacji miar (w języku DAX), model w Power BI działa w trybie **Import**. Oznacza to, że po odświeżeniu hurtowni, silnik Power BI zaciąga skompresowaną kopię danych z Azure SQL do swojej pamięci operacyjnej. Gwarantuje to maksymalną płynność działania interaktywnych dashboardów bez konieczności ciągłego odpytywania bazy (co miałoby miejsce w trybie *DirectQuery*).

7.2 Model semantyczny i relacje w narzędziu BI

7.3 Transformacje i miary kalkulowane (DAX)

Stworzono osobną tabelę do przechowywania 4 miar zaprojektowanych w języku DAX:

- **AvgYearlySalary** – średnia z `salary_mean` dla wszystkich ofert.
- **Total_Education_Cost_USD** – szacowany, całkowity koszt podjęcia studiów i relokacji. Miara ta dynamicznie sumuje roczne czesne (`Tuition_USD`), koszty życia (`Rent_USD` zannualizowane na 12 miesięcy) i ubezpieczenia (`Insurance_USD`). Koszty życia i ubezpieczenia są mnożone przez czas trwania danego programu nauczania pobrany z wymiaru (`Duration_Years`). Do całości doliczana jest także jednorazowa opłata wizowa (`Visa_Fee_USD`).
- **Career_ROI_5y** – autorski, główny wskaźnik biznesowy, określający zwrot z inwestycji po 5 latach aktywności zawodowej. Oblicza on zysk netto z 5 lat pracy (pięciokrotność `Avg_Yearly_Salary_USD` pomniejszona o `Total_Education_Cost_USD`), a następnie dzieli go przez całkowity poniesiony koszt edukacji. Wynik pozwala łatwo ocenić opłacalność relokacji.
- **Number_Of_Offers** – całkowita podaż ofert pracy na danym rynku, agregowana za pomocą funkcji `COUNT` zliczającej wystąpienia atrybutu `company` w tabeli faktów ofert pracy.


8 Realizacja przykładowych raportów dla użytkownika

8.1 Globalny Dashboard Career-ROI (Perspektywa Makro)

Widok analityczny poziomu makro służy do globalnego porównania opłacalności relokacji edukacyjnej oraz analizy trendów na rynku pracy IT. Zrealizowany raport opiera się na następujących elementach wizualnych:

- **Karty KPI:** Wyświetlają globalne podsumowanie dla widocznego zakresu danych: średnią oferowaną roczną pensję w branży IT (`Average Salary in IT`), średni wskaźnik zwrotu z inwestycji w edukację (`Average ROI of education`) oraz uśredniony całkowity koszt edukacji wraz z relokacją.
- **Mapa Bąbelkowa (Map with Career ROI indicator):** Przestrzenna wizualizacja rynków docelowych na mapie świata. Rozmieszczenie i właściwości punktów pozwalają na błyskawiczną identyfikację regionów o najwyższym potencjale zwrotu z inwestycji (Career-ROI) dla wybranych kierunków.
- **Zgrupowany Wykres Kolumnowy:** Zestawia ze sobą dwie kluczowe metryki: średnie roczne wynagrodzenie (`Avg_Yearly_Salary_USD`) oraz całkowity koszt edukacji (`Total_Education_Cost_USD`) w rozbiciu na państwa. Pozwala to na bezpośrednie porównanie barier wejścia (kosztów) do potencjalnych zysków dla różnych lokalizacji (np. USA, Wielka Brytania, Nowa Zelandia).

- **Mapa Drzewa (Treemap):** Ilustruje strukturę chłonności rynku pracy w podziale na formę zatrudnienia (np. `full_time`, `part_time`). Podkategorie wewnątrz kafelków wizualizują najpopularniejsze stanowiska (m.in. Data Engineer, Data Scientist, Data Analyst), a wielkość prostokątów odzwierciedla wolumen ofert.
- **Tabela TOP 10 Pracodawców:** Przedstawia ranking dziesięciu firm lub agencji rekrutacyjnych wykazujących największe zapotrzebowanie na specjalistów w wybranych regionach, bazując na liczbie aktywnych ogłoszeń (`Number_Of_Offers`).




Rysunek 5: Globalny Dashboard Career-ROI

8.2 Projekt Symulatora Kosztów (Perspektywa Mikro)

Widok operacyjny dedykowany bezpośrednio kandydatom na studia. Umożliwia precyzyjne oszacowanie obciążeń finansowych dla wybranej ścieżki edukacyjnej oraz weryfikację realnych możliwości podjęcia pracy w docelowym mieście, ułatwiając ostateczną decyzję o relokacji. Raport składa się z następujących komponentów:

- **Panel Filtrowania (Ścieżka Wyboru Kandydata):** Sekcja interaktywnych fragmentatorów, pozwalająca na wielowymiarowe zawężenie danych. Została podzielona na dwie kategorie:
 - **Filtry obowiązkowe:** Hierarchiczny lejek wyboru lokalizacji oraz profilu kształcenia (Kraj → Miasto → Uczelnia → Program studiów).
 - **Filtry opcjonalne:** Opcjonalne zawężenie przeglądanych wakatów na docelowym rynku z wykorzystaniem atrybutów stanowiska, preferowanej firmy oraz wymiaru etatu.

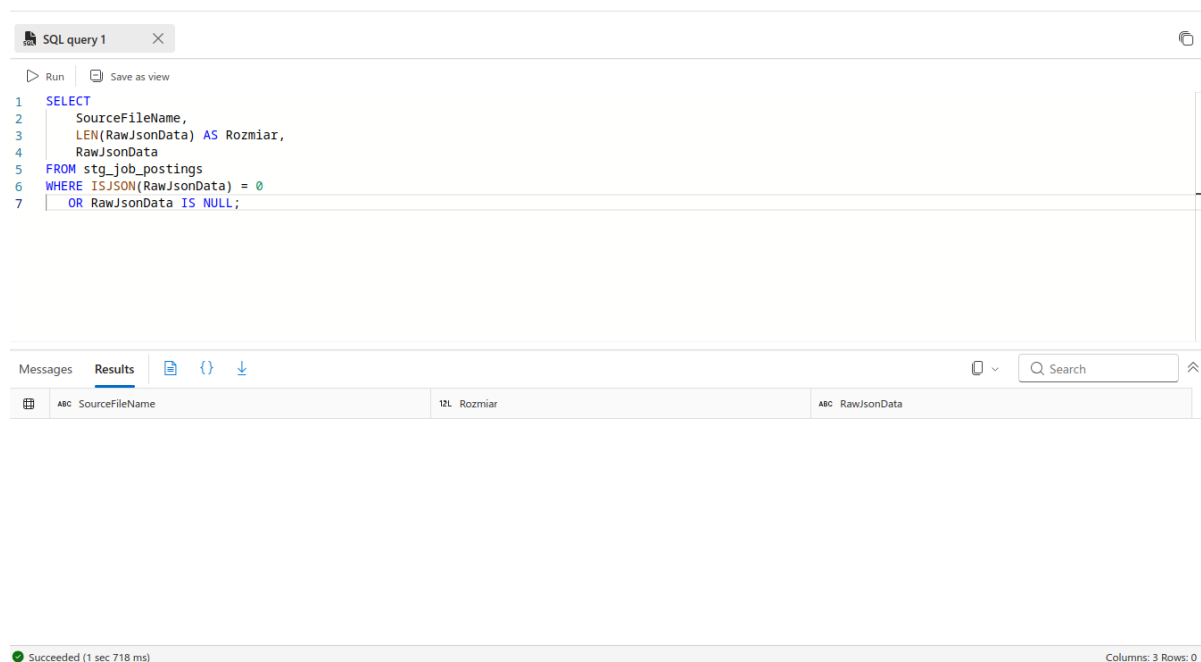
- **Wykres Kaskadowy (Kalkulator Kosztów Relokacji):** Główny wykres finansowy budujący strukturę kapitału początkowego potrzebnego na rozpoczęcie nauki. Kaskadowo sumuje poszczególne obciążenia z wybranej uczelni i miasta: roczne czesne (`Tuition_USD`), estymowany roczny koszt wynajmu ($\text{czynsz} \times 12$), koszty ubezpieczenia zdrowotnego oraz jednorazową opłatę wizową, wskazując prawą skrajną kolumną całkowity koszt pierwszego roku.
- **Karty Informacyjne (Kontekst Kandydata):** Metryki podsumowujące specyfikę wybranego profilu edukacyjnego, informujące kandydata o długości trwania wybranych studiów oraz podające Wskaźnik Kosztów Życia dla wybranego miasta, co stanowi istotny kontekst dla codziennych, nieuwzględnionych na wykresie wydatków.
- **Lista Wakatów (Dowód z Rynku):** Moduł prezentujący bezpośredni wgląd w dynamiczne dane z API dla przefiltrowanej konfiguracji. Dostarcza kandydatowi listę aktualnych ogłoszeń obejmującą kluczowe informacje, takie jak: rola, firma, oferowane wynagrodzenie w lokalnej walucie oraz bezpośredni adres URL do aplikacji.



Rysunek 6: Projekt Symulatora Kosztów

9 Testy funkcjonalne systemu (End-to-End)

W celu weryfikacji poprawności działania całej architektury przeprowadzono testy funkcjonalne. Scenariusze testowe uwzględniają zarówno inicjalizację systemu, jak i kolejne iteracje ładowania danych (tzw. zasilanie przyrostowe).



Rysunek 7: Testowanie poprawności plików json

9.1 Test 1: Inicjalizacja systemu i warstwa ELT (Pobieranie danych)

Cel: Weryfikacja poprawnego połączenia z zewnętrznym źródłem (Adzuna API), pobrania danych konfiguracyjnych z tabeli kosztów oraz poprawnego zapisu surowych plików JSON w warstwie stagingowej przy pustej bazie danych.

Kroki testowe:

1. Wyczyszczenie wszystkich tabel w hurtowni danych (Truncate).
2. Uruchomienie potoku PL_Ingest_Adzuna w Azure Data Factory.
3. Wykonanie kwerendy zliczającej wiersze w tabeli stg_job_postings oraz weryfikującej format funkcją ISJSON().

```

1 SELECT
2     SourceFileName ,
3     LEN(RawJsonData) AS Rozmiar ,
4     RawJsonData
5 FROM stg_job_postings
6 WHERE ISJSON(RawJsonData) = 0
7      OR RawJsonData IS NULL;


```

Listing 1: Weryfikacja integralności surowych danych w warstwie Staging

Oczekiwany wynik kwerendy: 0 rekordów.

Oczekiwany wynik: Potok kończy się statusem *Succeeded*. Tabela stagingowa zostaje zasilona surowymi danymi, a każda wartość w kolumnie *RawJsonData* jest poprawnym obiektem JSON (*ISJSON* = 1). Liczba wierszy odpowiada liczbie zdefiniowanych miast.

Potwierdzenie uzyskania wyniku:



Rysunek 8: Log z wykonania potoku w Azure Data Factory oraz wynik walidacji formatu JSON w Azure Data Studio.

9.2 Test 2: Poprawność transformacji i spójność relacyjna (Hurtownia Danych)

Cel: Potwierdzenie bezbłędnego działania procedur składowanych (usp_01 oraz usp_99), w tym mechanizmu automatycznego zasilania wymiarów (Inferred Members) oraz zachowania integralności kluczy obcych.

Kroki testowe:

1. Wykonanie kwerendy sprawdzającej rozrost tabel wymiarów (np. DimCompanies, DimTerritory) po załadowaniu nowych ofert.
2. Uruchomienie zapytań weryfikujących występowanie duplikatów (grupowanie po job_id) oraz tzw. wierszy osieroconych (brak przypisanego wymiaru czasu lub lokalizacji w tabeli faktów).

Oczekiwany wynik: Tabele wymiarów automatycznie generują nowe identyfikatory (Surrogate Keys) dla nieznanych wcześniej firm i stanowisk. Zapytania weryfikujące zjawisko namnażania wierszy (fan-out) oraz błędy relacyjne zwracają dokładnie 0 rekordów.

Potwierdzenie uzyskania wyniku:

Messages Results		
	ABC Typ_Bledu	123 Ilosc_Bledow
1	Brak Lokalizacji	0
2	Brak Firmy	41
3	Brak Atrybutow	0

Rysunek 9: Zestawienie wyników kwerend sprawdzających jakość danych i integralność referencyjną tabeli faktów.

9.3 Test 3: Scenariusz kolejnej iteracji (Zarządzanie statusem is_active)

Cel: Weryfikacja zaawansowanej logiki UPSERT obsługującej Slowly Changing Dimensions (SCD) na poziomie faktów – cykl życia oferty pracy.

Kroki testowe:

1. Ręczna modyfikacja rekordu w tabeli `fact_job_postings` (zmiana flagi `is_active` z 1 na 0 dla oferty, która wiemy, że nadal widnieje w API).
2. Ponowne uruchomienie całego potoku ELT.
3. Weryfikacja stanu zmodyfikowanego rekordu oraz identyfikacja nowych ofert dodanych w tej iteracji.

Oczekiwany wynik: Procedura ładująca poprawnie identyfikuje "wznowioną" ofertę i zmienia jej flagę powrotnie na 1 (Reaktywacja). Oferty, które zniknęły z API, otrzymują status 0 (Dezaktywacja), natomiast całkowicie nowe wpisy są dodawane z flagą 1. Zjawisko dublowania `job_id` nie występuje.

Potwierdzenie uzyskania wyniku:

job_id	title	is_active
1993882092	Data Analyst	False


job_id	title	is_active
1993882092	Data Analyst	True

Rysunek 10: Wyciąg z bazy danych przed i po zasileniu przyrostowym, obrazujący zmianę flagi aktywności.

9.4 Testowanie potoków w Azure Data Factory

Poza testami na poziomie silnika bazodanowego, architektura chmurowa umożliwia izolowane testowanie poszczególnych komponentów (ang. *unit testing*). W środowisku Azure Data Factory można swobodnie dezaktywować wybrane elementy potoku ELT, co pozwala na zawężenie obszaru poszukiwania błędów.

Na poniższym zrzucie ekranu (Rysunek 11) przedstawiono wyłączenie aktywności odpowiedzialnej za pobieranie plików z zewnętrznego źródła. Taki zabieg pozwala na bezpieczne, wielokrotne testowanie samego przetwarzania i transformacji danych, które znajdują się już w wewnętrznej warstwie stagingu, bez ryzyka wyczerpania limitów zapytań REST API.



Rysunek 11: Przykład dezaktywacji poszczególnych aktywności w potoku Azure Data Factory w celu izolowanego testowania.

9.5 Walidacja End-to-End na warstwie prezentacyjnej (Raporty BI)

Cel: Potwierdzenie pełnej spójności przepływu danych pomiędzy systemem bazodanowym a interfejsem graficznym (Power BI) dla różnych widoków analitycznych, w tym weryfikacja logiki filtrów kaskadowych, agregacji głównych wskaźników KPI oraz zestawień rankingowych.

Scenariusz A: Weryfikacja logiki filtrów kaskadowych

Kroki testowe:

1. Wybór testowej ścieżki w panelu filtrowania raportu Power BI (np. Kraj: *Australia*, Miasto: *Sydney*).
2. Odczytanie wartości wygenerowanych przez miary DAX na Wykresie Kaskadowym (Koszty Relokacji) oraz zliczenie wakatów w szczegółowej tabeli ofert.
3. Wykonanie analogicznej agregacji danych bezpośrednio w silniku SQL (złączenie `fact_job_postings` z `fact_education_cost` dla Sydney).

Oczekiwany wynik: Wartości finansowe widoczne na interfejsie użytkownika co do centa pokrywają się z wynikami zwracanymi przez silnik relacyjny. Panele filtrów zawodowych skutecznie zawężają listę firm wyłącznie do tych, które operują w wybranym mieście (prawidłowe działanie *Visual Filter Measure*).

Scenariusz B: Weryfikacja głównych KPI i rankingu firm

Kroki testowe:

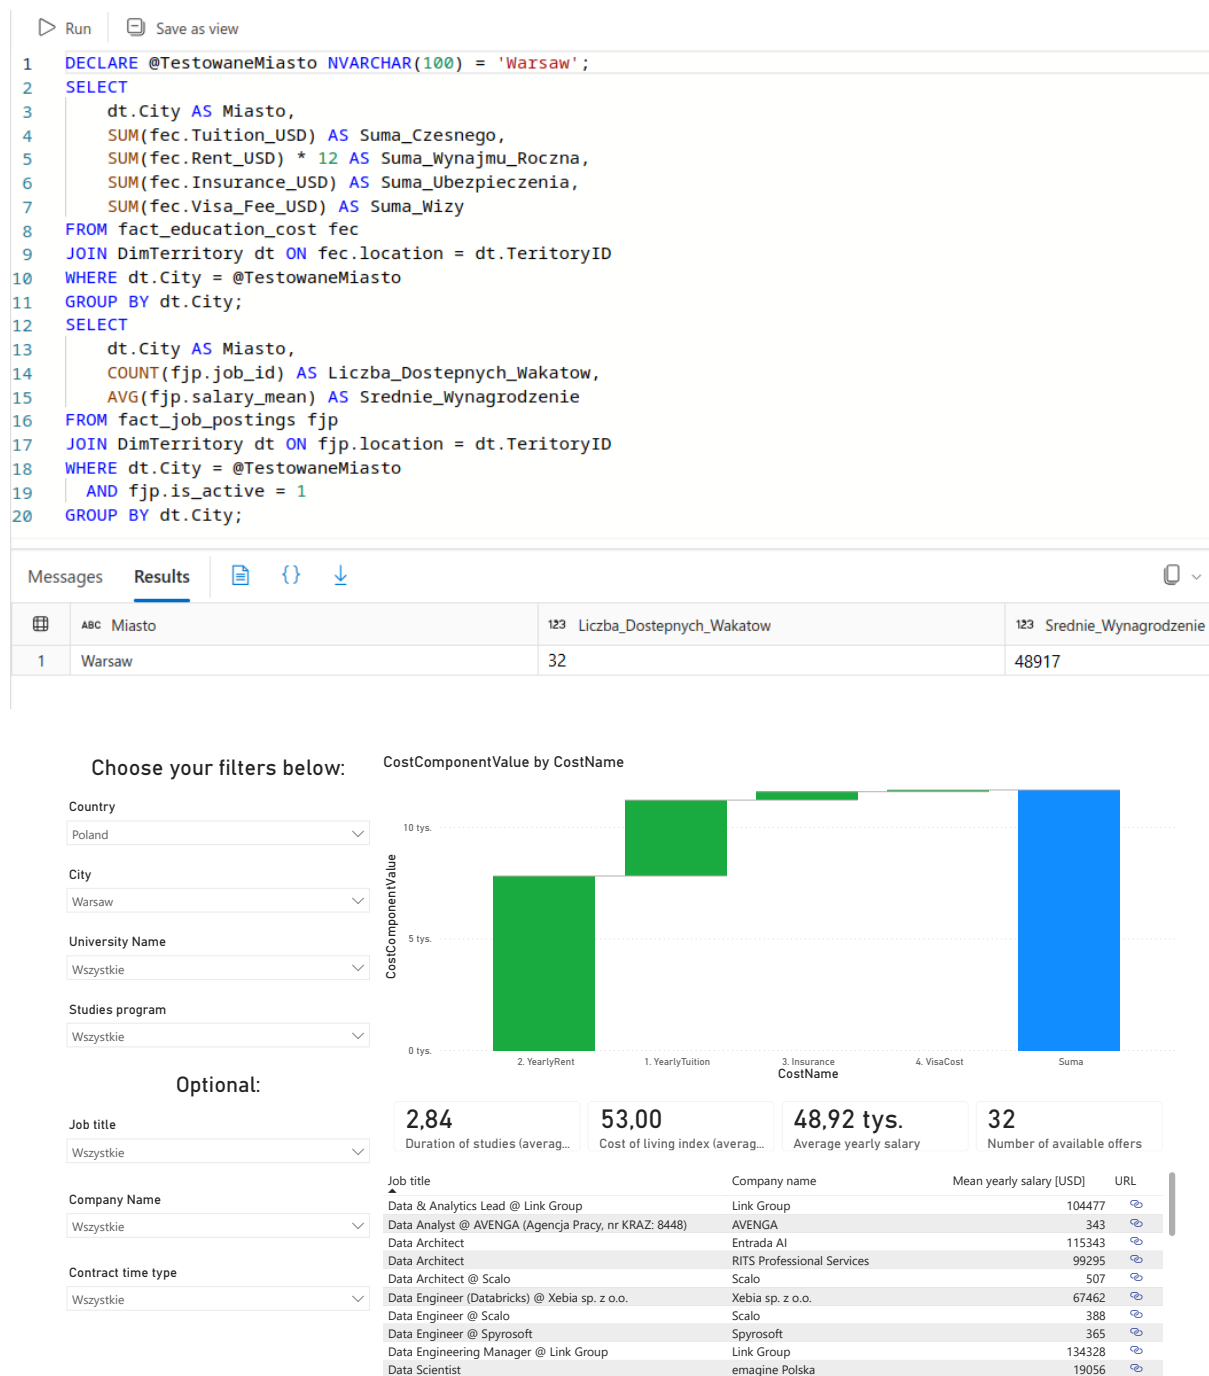
1. Odczytanie wartości wygenerowanych przez miary DAX na głównych kartach KPI: średnie roczne zarobki, średni koszt edukacji oraz średni zwrot z inwestycji (ROI).
2. Weryfikacja liczby przypisanych ofert dla czołowych pracodawców w tabeli „TOP 10 companies with most offers”.
3. Wykonanie analogicznej agregacji danych bezpośrednio w silniku SQL (wyliczenie średnich z tabeli `fact_job_postings` oraz wygenerowanie rankingu firm).

Oczekiwany wynik: Wartości widoczne na interfejsie użytkownika pokrywają się z wynikami zwracanymi przez silnik relacyjny, z uwzględnieniem wbudowanego w raport formatowania i zaokrągleń (prezentacja w tysiącach). Ranking TOP 10 firm wygenerowany w bazie danych w 100% odpowiada liście wyświetlanej na dashboardzie.


Potwierdzenie uzyskania wyników:

Oba przeprowadzone testy walidacyjne zakończyły się wynikiem pozytywnym. W przypadku pierwszego scenariusza (Rysunek 12), zliczenia wakatów dla poszczególnych firm oraz zagregowane koszty relokacji odczytane z interfejsu Power BI dla wybranego regionu są całkowicie zgodne z wynikami zwróconymi przez zapytanie SQL.

Weryfikacja drugiego scenariusza (Rysunek 13) potwierdziła poprawność mechaniki wyliczania globalnych wskaźników. Surowe wartości z SQL idealnie mapują się na sformatowane wskaźniki w Power BI. Średnie zarobki w SQL wynoszące 86487 USD są prezentowane jako 86,49 tys. USD na raporcie. Podobnie uśredniony koszt edukacji z bazy (59297 USD) jest poprawnie wyświetlany jako 59 tys. USD. Dodatkowo, ranking firm i zliczenia poszczególnych ofert zgadzają się co do jednego rekordu w obu środowiskach (np. Insight Global i Marchant Recruitment po 90 ofert, Deloitte 86 ofert).



Rysunek 12: Scenariusz A: Porównanie agregacji logiki filtrów kaskadowych widocznych na dashboardzie z wynikami zapytań SQL w środowisku produkcyjnym.



Rysunek 13: Scenariusz B: Porównanie agregacji wskaźników KPI oraz rankingu firm widocznych na dashboardzie z wynikami zapytań SQL.

10 Podział prac

Jan Taran: zaprojektowanie i implementacja bazy danych oraz procesu Transform, przetestowanie całego procesu, wykonanie raportu z perspektywą Mikro.

Piotr Wysocki: zaprojektowanie procesu Extract oraz Load, rozbudowanie i ulepszanie procedur składowanych w etapie Transform, integracja z PowerBI z implementacją potrzebnych miar oraz wykonanie raportu z perspektywą Makro.

11 Podsumowanie i ocena biznesowa rozwiązania

Zaprojektowanie i implementacja systemu integracji danych rynkowych i edukacyjnych pozwoliło na pełną realizację założeń biznesowych. Zaprojektowana architektura chmurowa oraz warstwa raportowa dostarczają gotowy produkt analityczny wysokiej jakości, którego wartość można jednoznacznie ocenić przez pryzmat kluczowych kryteriów biznesowych:

11.1 Realizacja strategicznego celu biznesowego

Główny cel projektu – likwidacja problemu uciążliwego rozproszenia informacji i optymalizacja procesu decyzyjnego kandydata – został w pełni osiągnięty. Dzięki konsolidacji statycznych kosztów akademickich z dynamicznym strumieniem ofert pracy z API Adzuna, system dostarcza unikalną wartość poznawczą w postaci wskaźnika **Career-ROI_{5y}**.

Zamiast zmuszać użytkownika do manualnego porównywania dziesiątek zestawień, system prezentuje syntetyczną rekomendację ekonomiczną. Pozwala to na transformację modelu operacyjnego: czas potrzebny na przygotowanie wieloaspektowej analizy relokacyjnej dla klienta został skrócony z kilkunastu godzin do zaledwie kilku sekund interakcji z dashboardem.

11.2 Ocena jakości rozwiązania z perspektywy biznesu

Wysoka jakość techniczna wdrożonego systemu bezpośrednio przekłada się na mierzalne korzyści biznesowe i operacyjne:

- **Zaufanie do danych (Data Trust):** Rezultaty przeprowadzonych testów funkcjonalnych typu *End-to-End* udowodniły absolutną szczelność i bezbłądność „lejka danych”. Klienci podejmujący decyzje o wysokim ryzyku finansowym otrzymują produkt bezkompromisowo bezpieczny i oparty na twardych faktach.
- **Efektywność kosztowa i bezobsługowość (Operational Efficiency):** System samodzielnie dba o przyrostowe zasilanie wakatów, czyszczenie duplikatów oraz historyzację zmian (SCD Type 2) wskaźników kosztów życia (**LivingCostIndex**).

11.3 Skalowalność i perspektywy rozwoju

Fizyczny model hurtowni danych oparty na architekturze gwiazdy/galaktyki wykazuje doskonałą elastyczność rozwojową. Struktura pozwala na bezproblemowe podłączanie kolejnych dynamicznych źródeł danych (np. API innych lokalnych portali rekrutacyjnych) lub rozbudowę wymiaru akademickiego bez naruszania integralności obecnych tabel faktów.

Podsumowując, stworzone rozwiązanie stanowi stabilne, wysoce wydajne i zorientowane na cele biznesowe narzędzie klasy Business Intelligence. W pełni automatyzuje proces analizy opłacalności migracji edukacyjnej, stanowiąc niezawodny fundament dla budowania świadomości finansowej i zawodowej młodych specjalistów sektora IT.